

Estruturas e Implementações Avançadas do Ecossistema caRtola: Um Guia Técnico para Ciência de Dados no Futebol

O projeto caRtola, liderado por Henrique Gomide e Arnaldo Gualberto, consolidou-se como a principal referência de código aberto para a extração, tratamento e modelagem preditiva de dados do Cartola FC.¹ Esta análise técnica detalha os fundamentos matemáticos, as estratégias de engenharia de software e os algoritmos de otimização contidos nos tutoriais do repositório, fornecendo um roteiro exaustivo para a sua implementação em sistemas de análise esportiva.

Arquitetura de Dados e Fundamentos de Engenharia de Software

A base do sistema reside na integridade de dados históricos de 2014 a 2023, armazenados em data/01_raw.¹ A transição para o framework Kedro permite a criação de pipelines modulares (Raw, Primary, Feature), enquanto o Poetry gerencia dependências cruciais como pandas, scikit-learn e PuLP.¹

Componente	Descrição	Ferramenta
Orquestração	Pipelines modulares e versionados	Kedro
Gestão de Ambiente	Isolamento de dependências	Poetry
Ingestão	Leitura de CSVs históricos via Python	Pandas

Implementação de Leitura e Limpeza

O tutorial de ingestão ensina a percorrer a árvore de diretórios para unificar centenas de arquivos. Um ponto crítico na implementação é a normalização: dados de 2014-2019 exigiram padronização de formatos e tratamento de variabilidade por meio de médias. A leitura pode ser iniciada apontando para as URLs de dados brutos do repositório, como <https://raw.githubusercontent.com/henriquepgomide/caRtola/master/data/2019/2019-medias-jogadores.csv>.

Modelagem de Dificuldade de Jogo e Pontos Cedidos

A implementação da "Dificuldade de Jogo" no projeto caRtola não é subjetiva, mas baseada em estimativas estatísticas de probabilidade de vitória e expectativa de gols.

1. Dificuldade via Regressão de Poisson

Para quantificar a dificuldade de um confronto, utiliza-se a Regressão de Poisson para modelar a expectativa de gols (λ) de cada equipe. A dificuldade para um defensor, por exemplo, é inversamente proporcional à probabilidade do adversário marcar gols:

$$P(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}$$

Ao calcular o λ (média de gols marcados/sofridos) ajustado pelo mando de campo, o sistema gera um índice de "Clean Sheet" (SG). Confrontos com baixa expectativa de gols adversários são classificados como de "baixa dificuldade" para a defesa.

2. Análise de Pontos Cedidos

A métrica de pontos cedidos é implementada através da análise de "Média com mando de campo". O pipeline de dados deve:

- Calcular a média de pontos que cada time cede para cada posição (ex: quantos pontos, em média, a defesa do Time X cede para Atacantes adversários).
- Diferenciar o desempenho "Casa vs. Fora", pois a vantagem do mandante altera drasticamente a cedência de scouts como desarmes e finalizações.
- Utilizar essas médias padronizadas como *features* em modelos de regressão (XGBoost) para prever a pontuação de um jogador no confronto específico.

A Economia do Cartola: Algoritmos de Valorização

O sistema de valorização é abordado em profundidade para garantir a sustentabilidade financeira do time.

- **Rodada 1:** Utiliza-se um modelo linear onde a valorização depende do desempenho vs. preço baixo. A reta de regressão observada tem coeficiente próximo a 0,69.

- **Rodadas seguintes:** O algoritmo migra para uma lógica de correção de preços baseada em médias móveis ponderadas, onde o jogador precisa superar sua média atual para valorizar.

Otimização e Inteligência Preditiva

O auge da sofisticação está na "Seleção automática via Programação Linear".

- **PuLP:** Utilizado para resolver o problema da mochila, maximizando $\sum P_i x_i$ sob restrições de orçamento e tática.
- **Cadeias de Markov:** Implementadas para avaliar a consistência, filtrando jogadores que "oscilam" demais entre pontuações altas e negativas.
- **Affinity Propagation:** Algoritmo de clusterização (R/Python) que agrupa jogadores por perfil técnico (ex: "finalizadores" vs "garçons") sem necessidade de definir o número de grupos a priori. Isso ajuda a identificar substitutos ideais que mantenham o perfil de pontuação cedida/conquistada.

Roteiro de Implementação Técnica

1. **Ingestão:** Criar scripts Python usando pandas para ler os CSVs das rodadas. Tratar duplicatas de IDs e normalizar scouts históricos (ex: transformar "Roubadas de Bola" em "Desarmes").
2. **Feature Engineering:** Calcular as colunas de "Dificuldade do Confronto" (via Poisson) e "Média Cedida pelo Adversário" (agregando pontos por posição das rodadas anteriores).
3. **Modelo Preditivo:** Treinar um regressor (Random Forest ou XGBoost) usando as médias de mando e a dificuldade como variáveis de entrada.
4. **Otimizador:** Alimentar as predições no modelo PuLP para gerar a escalação automática respeitando o patrimônio em cartoletas.

O ecossistema caRtola demonstra que o sucesso no jogo depende da minimização de riscos através da estimativa matemática de probabilidades, transformando dados brutos em inteligência competitiva.

Referências citadas

1. henriquepgomide/caRtola: Extração de dados da API do CartolaFC, análise exploratória dos dados e modelos preditivos em R e Python - 2014-22. [EN] Data munging, analysis and modeling of CartolaFC - the most popular fantasy football game in Brazil. Data cover years 2014-23. - GitHub, acessado em março 10, 2026, <https://github.com/henriquepgomide/caRtola>
2. caRtola/README.md at master · henriquepgomide/caRtola · GitHub, acessado em março 10, 2026, <https://github.com/henriquepgomide/caRtola/blob/master/README.md>